

Tarefa Computacional 2

Metodologia:

Para implementação deste trabalho foi construído uma rede neural do tipo *feedforward*, com número de pesos de entrada igual número de atributos da entrada; com 5 pesos na camada oculta, com exceção do algoritmo de PSO no dataset de breast cancer, que foram utilizados 6 pesos na camada intermediária; e número de pesos na camada de saída igual ao número de classes da base de dados utilizada. No algoritmo PSO, foi utilizada tangente hiperbólica como função de ativação na camada oculta, já no GA foi utilizada Relu como função de ativação na camada oculta. Em ambos os algoritmos, foi utilizado softmax como função de ativação na camada de saída.

O algoritmo de PSO foi inspirado no código do link https://pyswarms.readthedocs.io/en/development/examples/custom_objective_function.html, em que foi mudado número de pesos na camada oculta para 5, com exceção no uso da base de dados breast cancer, em que foi usado 6 pesos. Também foi mudado os parâmetros $c1$, $c2$ e w para 0.7, 0.2 e 0.95, respectivamente, com exceção no uso da base de dados breast cancer em que esses parâmetros foram setados para 0.8, 0.2 e 0.9, respectivamente. O número máximo de iterações é igual a 5000, com exceção do uso da base de dados Iris em que o número máximo de iterações é igual a 1000. Para computar a loss da rede foi escolhida a função log-verossimilhança.

O algoritmo de GA foi inspirado no código do link <https://blog.paperspace.com/train-keras-models-using-genetic-algorithm-with-pygad/>, na seção Complete Code for Classification Using a CNN. Foi mudado o tipo de rede neural, para a rede neural descrita anteriormente. Foi alterado o método de crossover de um-ponto para dois-pontos, foi alterado o método de seleção de *Steady State* para ranking e foi mantido o método de mutação em randômica. O número de indivíduos em cada geração é igual a 100. E o número máximo de gerações é igual a 200. Para computar a fitness da rede foi escolhida a função entropia cruzada.

Este trabalho foi realizado em duas etapas chamadas treino e teste. Na fase de treino foi utilizado 75% de cada base de dados do trabalho para treinar a rede neural de cada algoritmo implementado neste trabalho e na fase de teste foi utilizado 25% da base de dados para testar as redes neurais implementadas neste trabalho

Resultados:

Para avaliação deste trabalho foi usado como métricas: acurácia, f1-score, recall, precisão e tempo de execução em segundos. As tabelas abaixo apresentam os resultados de cada algoritmo implementado neste trabalho, junto com os resultados do artigo *Training of feedforward neural networks for data classification using hybrid particle swarm optimization, Mantegna Lévy flight and neighborhood search*, aqui descrito como LPSONs. Estas tabelas apresentam a média e desvio padrão de cada métrica descrita anteriormente, executado 15 vezes em cada base de dados do trabalho para as fases de treino e de teste.

Tablea 1: Tabela de Acurácia, f1-score, recall e precisão na fase de treino na base de dados Iris

	PSO	GA	LPSONs
Média acurácia	0.9827	0.9833	0.9752
Desvio padrão acurácia	0.0022	0.0044	0.0163
Média f1-score	0.9828	0.9834	0.9754
Desvio padrão f1-score	0.0022	0.0044	-
Média precisão	0.9828	0.9835	0.9854
Desvio padrão precisão	0.0023	0.0044	-

Média recall	0.9828	0.9833	0.9747
Desvio padrão recall	0.0021	0.0044	-

Tablea 2: Tabela de Acurácia, f1-score, recall e precisão na fase de teste na base de dados Iris

	PSO	GA	LPSONS
Média acurácia	0.9947	1	0.9755
Desvio padrão acurácia	0.0105	0	0.0286
Média f1-scrore	0.9947	1	0.9637
Desvio padrão f1-score	0.0105	0	-
Média precisão	0.9952	1	0.9684
Desvio padrão precisão	0.0095	0	-
Média recall	0.9945	1	0.9609
Desvio padrão recall	0.0108	0	-

Tablea 3: Tabela de Acurácia, f1-score, recall e precisão na fase de treino na base de dados Wine

	PSO	GA	LPSONS
Média acurácia	0.9629	0.7378	1
Desvio padrão acurácia	0.0319	0.0952	0
Média f1-scrore	0.9633	0.6551	0.9977
Desvio padrão f1-score	0.0319	0.1533	-
Média precisão	0.9711	0.6424	1
Desvio padrão precisão	0.0228	0.1793	-
Média recall	0.9604	0.7043	0.9980
Desvio padrão recall	0.0353	0.1210	-

Tablea 4: Tabela de Acurácia, f1-score, recall e precisão na fase de teste na base de dados Wine

	PSO	GA	LPSONS
Média acurácia	0.9629	0.7837	0.95009
Desvio padrão acurácia	0.0288	0.1040	0.0328
Média f1-scrore	0.9633	0.6929	0.9553
Desvio padrão f1-score	0.0290	0.1649	-
Média precisão	0.9662	0.6688	0.9690
Desvio padrão precisão	0.0233	0.1931	-
Média recall	0.9654	0.7475	0.9580
Desvio padrão recall	0.0297	0.1328	-

Tablea 5: Tabela de Acurácia, f1-score, recall e precisão na fase de treino na base de dados Breast Cancer

	PSO	GA	LPSONS
Média acurácia	0.9498	0.6751	0.9759
Desvio padrão acurácia	0.0156	0.0714	0.0041
Média f1-score	0.946	0.4461	0.9738
Desvio padrão f1-score	0.0165	0.1343	-
Média precisão	0.9392	0.4654	0.9615
Desvio padrão precisão	0.0176	0.2338	-
Média recall	0.9558	0.5372	0.9749
Desvio padrão recall	0.0143	0.1089	-

Tablea 6: de Acurácia, f1-score, recall e precisão na fase de teste na base de dados Breast Cancer

	PSO	GA	LPSONS
Média acurácia	0.9633	0.6745	0.9648
Desvio padrão acurácia	0.0128	0.0746	0.0072
Média f1-score	0.9598	0.4416	0.9613
Desvio padrão f1-score	0.0139	0.1370	-
Média precisão	0.9583	0.4681	0.9478
Desvio padrão precisão	0.0160	0.2380	-
Média recall	0.9616	0.5349	0.9617
Desvio padrão recall	0.0119	0.1108	-

Tablea 7: Tabela com tempo médio de execução dos algoritmos em cada base de dados em segundos

	PSO	GA	LPSONS
Tempo médio de execução na base de dados Iris	45	367	241
Tempo médio de execução na base de dados Wine	34	351	241
Tempo médio de execução na base de dados Breast Cancer	70	380	237

As figuras abaixo apresentam a média de loss por iteração da rede neural do algoritmo de PSO nas bases de dados do trabalho:

Figura 1: Média de Loss por número de iterações na base de dados Iris




Figura 2: Média de Loss por número de iterações na base de dados Wine

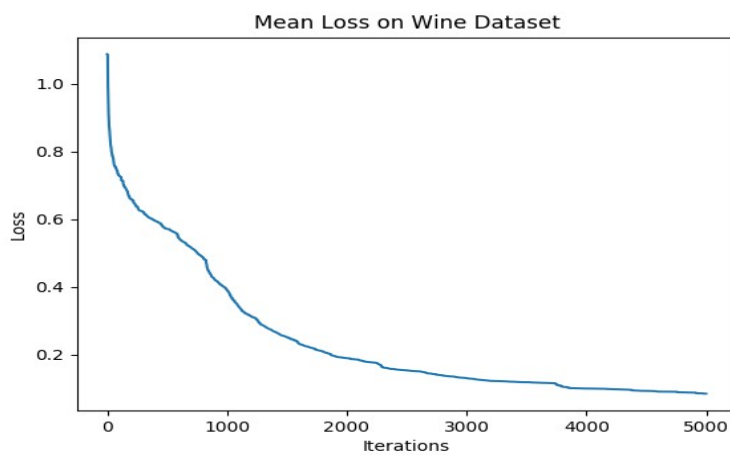
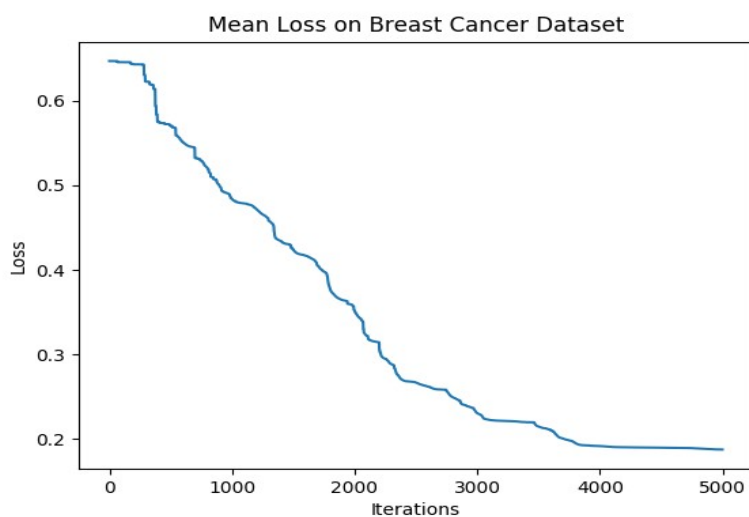


Figura 3: Média de Loss por número de iterações na base de dados Breast Cancer



As figuras abaixo apresentam a média de fitness por geração da rede neural do algoritmo de GA nas bases de dados do trabalho:

Figura 4: Média de Fitness por número de gerações na base de dados Iris




Figura 5: Média de Fitness por número de gerações na base de dados Wine

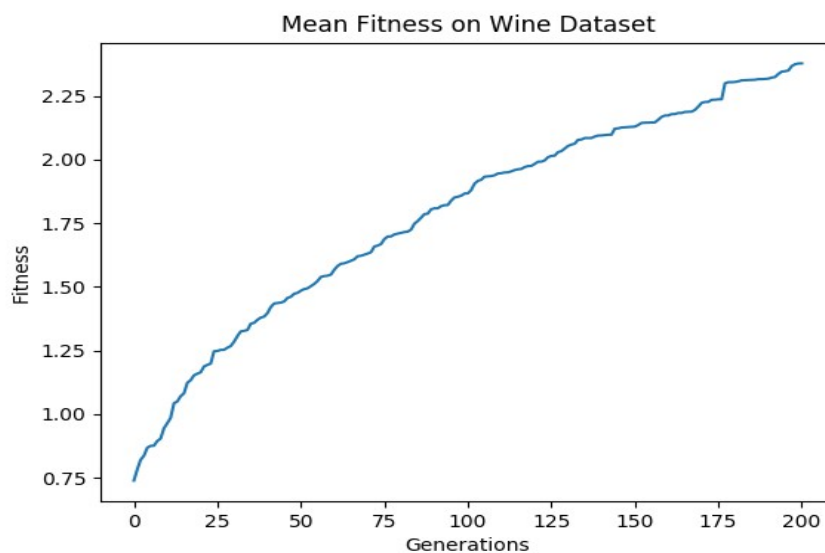
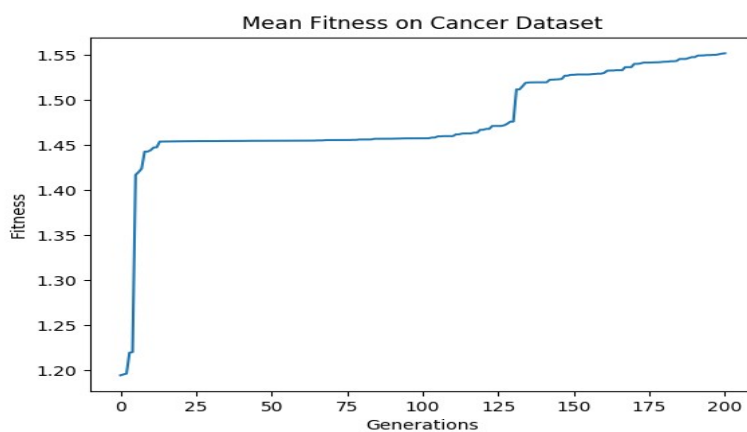


Figura 6: Média de Fitness por número de gerações na base de dados Breast Cancer



Conclusão:

Podemos concluir que o algoritmo de PSO ganhou em praticamente em todas as médias de acurácia e f1-score das bases de dados de teste, perdendo apenas por pouquíssimo (0,33%) na base de dados Breast Cancer para algoritmo LPSONs do artigo. Também obtve resultados satisfatórios tanto na acurácia como no f1-score nas base dados de treino perdendo por cerca 3% nessas métricas para o algoritmo LPSONs. Contudo, o tempo médio de execução do algoritmo de PSO é pelo menos cerca de 3 vezes mais rápido que o algoritmo LPSONs.

Podemos perceber que o algoritmo de GA foi o que obteve as melhores métricas de acurácia e f1-score na base da dados Iris, tanto nas fases de treino e teste. Porém ele obteve métricas ruins tanto na acurácia e f1-score nas bases de dados Wine e Breast Cancer tanto na fase de treino e de teste. Uma possível solução para isso seria aumentar o número máximo de gerações, já que os gráficos de fitness demonstram que o valor de fitness tem uma tendência a aumentar conforme as gerações iam passando para essas bases de dados, contudo isso iria aumentar o tempo de execução desse algoritmo.

Por fim podemos concluir que o algoritmo de PSO é o melhor algoritmo apresentado neste trabalho para resolver o problema de classificação proposto neste trabalho, devido em média apresentar os melhores resultados nas métricas avalidas neste trabalho.